

可核验的弃权:让 AI 漏损诊断 “敢用、可问责”

一份以算例为主线的通俗教程

本教程配套论文 *Verifiable abstention makes AI leak diagnosis accountable in water distribution networks*(以下简称“论文”)。写给三类读者:第一次接触这个课题的研究生、想知道“这东西到底怎么决定挖不挖”的供水企业工程师,以及想快速判断论文说了什么、没说什么的评审人。

阅读约定:**每一节先讲例子,再给公式,再算一遍**。凡标注“论文数据”的数字都可以在论文正文、补充材料(SI)或代码仓库的 `artifacts/*.json` 里逐一找到;凡标注“玩具算例”的数字是为了教学专门构造的小例子,与真实管网无关,但每一步计算都是真的,完整脚本见 `docs/tutorial_examples.py`,可以自己跑一遍核对。

第 1 章 问题:为什么“猜得准”还不够

1.1 一个 100 次报警的算例

想象一家水司一年收到 100 次压力异常报警,每次报警都要决定:派不派开挖队?

论文在 EXA7 基准管网(一个公开的仿真测试管网,详见 4.1)上给出了两个系统的表现(论文数据,Results 的 EXA7 一节):

	传统“强制定位”系统	本文的“可核验弃权”系统
收到 100 次报警后	每次都给一个最可能的位置, 开挖 100 次	只在证据充分时行动, 开挖约 40 次
其中挖错的	约 68 次	1 到 2 次
剩下的报警	无	约 60 次“弃权”:系统明确说“证据不足以支持开挖”,并给出原因

传统系统的定位准确率是 31.7%,也就是每三次开挖只有一次挖对。这不是它不努力,而是问题本身太难(下一节讲)。本文系统的关键不同在于:它**允许自己不回答**。它行动的那约 40 次里,96% 是对的。

成本上的直觉(纯举例): 假设一次错误开挖的综合成本是 1 万元(路面破拆、交通、人工、信誉;这是教学假设,论文只说“数千美元量级”)。那么 100 次报警下,传统系统浪费约 68 万元,本文系统约 1 到 2 万元。剩下的约 60 次报警并没有被“扔掉”,而是附上卷宗交给人工复核(在 City D 工单那一层,论文还加了第二层流量平衡巡查手段,见第 4 章)。

1.2 为什么这个问题天生难

论文引言列了三条(论文数据):

1. **反问题病态。** 一张管网几百到上千个节点,压力传感器只有二三十个。几十个数字要反推几百个位置里的一个,信息量根本不够,很多位置的“指纹”长得几乎一样。
2. **压力异常不一定是泄漏。** 用水高峰、传感器漂移、阀门被误关,都会让压力下降,长得像泄漏。
3. **没有一种主流方法能证明“我这次不该行动”。** 传统模型每次报警都会输出一个答案,可它没有机制说“这个答案我不敢负责”。

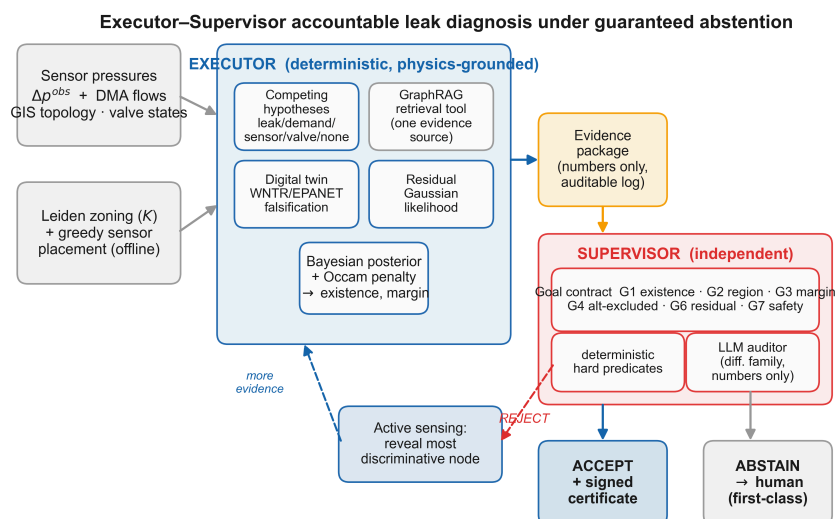
1.3 医生的做法:鉴别诊断

一个好医生面对胸痛病人,不会直接开刀。他会列出所有可能(心梗、肺栓塞、食道痉挛、肌肉拉伤),开最能区分它们的检查,排除到只剩一个才治疗;排除不了就留观。

论文把漏损定位改写成同一件事:**列出竞争假设、做最能区分的检验、证据不足就不动**。这就是“可核验的弃权”(verifiable abstention):不动不是失败,而是一种可以被审计的正式结论。

第 2 章 一句话看懂系统:两个智能体加一份合同

论文的系统由两个角色组成(论文 Fig. 2):



论文 Fig. 2:执行者与监督者架构

执行者(executor) 负责 “诊断”：

- 提出一整套**互斥且穷尽**的候选假设:某个分区漏了、某个分区用水异常、某个传感器坏了、某个阀门状态不对、或者根本没事;
- 把每个假设放进管网的**数字孪生**(WNTR/EPANET 水力模型)里跑一遍,看它能不能**重现**传感器读到的压力变化;重现不了的假设就被 “证伪”；
- 把所有假设的表现融合成一个**后验概率**,写成一份只含数字的**证据包**。

监督者(supervisor) 负责 “把关”：

- 从不自己定位,只审执行者的证据包;
- 拿一份写在代码里的**目标合同(goal contract)**逐条检查:泄漏存在吗、区域够小吗、领先优势够大吗、有没有别的解释、物理上重现了吗、安全吗;
- 三种结局:**批准派单**(附一份带哈希摘要的证书,谁也改不了)、**索要更多证据**(告诉执行者去补测哪个点)、**弃权**(交给别人,附上未排除的假设清单和每条检查失败的原因)。

外加一个**大语言模型审计员(LLM auditor)**:它只看证据包的数字摘要,不看任何文字叙述,只能在合同之上 “再加一票否决”,**永远不能推翻合同已经判定失败的硬检查**。它和执行者用的是不同厂家的模型,防止 “自己给自己打分”。

打个比方:这和现在一些编程智能体的 “目标模式” 是一个思路,一个模型干活,另一个只看结果的模型来判定目标有没有达成(论文引言提到 Claude Code 的这一模式);论文把这个思路从写代码搬到了 “要不要派人开挖” 上。

下面这句话请记住,它是全文的骨架:

执行者用物理孪生证伪假设,监督者用代码合同决定行不行动,语言模型只负责规划

第 3 章 玩具管网算例:把整条流水线手算一遍

从这一章开始是本教程的核心。我们构造一个足够小、能用手算的管网,把论文的公式 (2)、(3)、(4) 和 SI 公式 (S6) 逐个走一遍。

3.1 设定(玩具算例)

- 管网分成 **3 个分区**:A、B、C。玩具里直接给定;论文里分区是离线算出来的:先跑一次基线水力模拟,取每个节点的平均压力,把管网本身的连接(管道、泵、阀)作为图的边、两端平均压力的均值作为边权(**只在真实相连处赋权**,所以压力相近但不连通的节点绝不会被并到一起),权重线性缩放到 $[0,1]$ 后用 **Leiden 算法** 最大化带分辨率参数 γ 的模块度。 γ 控制的是粒度而不是分区数,所以在 $[0.001, 5]$ 上扫 300 个 γ ,取分区数最接近目标的那一个(EXA7 和 City D 取 15,另外三个大网取 25)。Leiden 是 Louvain 的改进版,好处是保证每个社区连通。
- 装了 **$m = 4$ 个压力传感器**:1 号、2 号在 A 区,3 号在 B 区,4 号在 C 区。
- 传感器噪声 **$\sigma = 0.05$ m**(水头单位“米”,0.05 m 相当于 5 厘米水柱的抖动;这是论文 EXA7 基准的设定)。
- 某天四个传感器相对于正常状态的压力变化(观测向量)是:

$$\Delta \mathbf{p}^{\text{obs}} = [-0.42, -0.38, -0.05, -0.02] \text{ m}$$

直觉上:A 区的两个传感器掉得很厉害,B、C 区几乎没动。像是 A 区漏了。但“像”不算数,要一个一个假设去验。

3.2 候选假设(玩具算例)

执行者列出 7 个假设。对每个假设,数字孪生给出“如果这个假设成立,4 个传感器应当读到什么”(预测向量 μ):

编号	假设	家族	孪生预测 $\mu(m)$	自由参数个数 k
H1	A 区某处泄漏(已在 A 区内搜到最佳节点和流量)	泄漏	[-0.40, -0.35, -0.06, -0.03]	2(节点、流量)
H2	B 区某处泄漏	泄漏	[-0.10, -0.12, -0.41, -0.36]	2
H3	C 区某处泄漏	泄漏	[-0.05, -0.04, -0.08, -0.40]	2
H4	A 区整体用水激增	需水异常	[-0.30, -0.30, -0.04, -0.02]	1(倍率)
H5	1 号传感器坏了	传感器故障	[-0.42, 0, 0, 0]	1(解释的通道数)
H6	阀门 V1 被误关	阀门误态	[-0.20, -0.25, -0.15, -0.10]	0
H7	什么都没发生	空假设	[0, 0, 0, 0]	0

两点说明:

- 泄漏假设的预测不是随便给的:论文里每个“某区泄漏”假设都在该区所有节点和一组流量档位上搜过,取残差最小的那个节点-流量组合(SI 公式 S4)。所以 H1 的 μ 已经是 A 区内最像观测的那一个。
- 传感器故障假设(H5)在**测量空间**里定义:它说“坏掉的那个通道读什么就是什么,别的通道都应该正常”。这正是它和泄漏的本质区别:泄漏会让**很多**传感器一起下降,故障只影响**少数**通道。

3.3 算例 1:残差与证伪(论文公式 2)

对每个假设算残差 r 、它的“每自由度马氏距离” ρ ,以及“对数似然” $\log L$ (在这个假设成立的前提下,观测到这组读数有多可能,取了对数;残差越大它越小):

$$\mathbf{r}_h = \Delta \mathbf{p}^{\text{obs}} - \boldsymbol{\mu}_h, \quad \rho_h = \frac{\|\mathbf{r}_h\|_2}{\sigma\sqrt{m}}, \quad \log \mathcal{L}(h) = -\frac{\|\mathbf{r}_h\|_2^2}{2\sigma^2} - m \log(\sigma\sqrt{2\pi})$$

ρ 的读法: $\rho \approx 1$ 表示“残差就是噪声水平,这个假设完全能重现观测”; ρ 明显大于 3 表示“差得太远,物理上不相容”,这个假设就被证伪了。

手算 H1(A 区泄漏):

$$\mathbf{r} = [-0.42 - (-0.40), -0.38 - (-0.35), -0.05 - (-0.06), -0.02 - (-0.03)] = [-0.02, -0.03, +0.01, +0.01]$$

$$\|\mathbf{r}\| = \sqrt{(0.0004 + 0.0009 + 0.0001 + 0.0001)} = \sqrt{0.0015} = 0.0387 \text{ m}$$

$$\rho = 0.0387 / (0.05 \times \sqrt{4}) = 0.0387 / 0.10 = \mathbf{0.39} \text{ (比噪声还小,完美重现)}$$

手算 H5(1 号传感器故障):

$r = [0, -0.38, -0.05, -0.02], ||r|| = \sqrt{(0.1444+0.0025+0.0004)} = 0.3838 \text{ m}, \rho = 0.3838/0.10 = \mathbf{3.84}$ (超过 3,证伪)

道理很直观:如果只是 1 号传感器坏了,2 号传感器不该跟着掉 0.38 m。它掉了,所以“传感器坏了”解释不通。

全部 7 个假设的结果(脚本 `tutorial_examples.py` 算例 1):

假设	$ r $ (m)	ρ	$\log L$	结论
H1 A 区泄漏	0.0387	0.39	+8.01	完美重现
H4 A 区需水异常	0.1446	1.45	+4.13	勉强能解释
H6 阀门 V1	0.2858	2.86	-8.03	很差
H5 传感器 1 故障	0.3838	3.84	-21.15	证伪
H7 无异常	0.5689	5.69	-56.43	证伪
H3 C 区泄漏	0.6307	6.31	-71.25	证伪
H2 B 区泄漏	0.6444	6.44	-74.73	证伪

注意 $\log L$ 的差距有多悬殊:H1 与 H2 相差 80 多个自然对数单位,也就是 e^{80} 倍。这就是“用孪生证伪”和“用相似度检索”的区别:检索只会说“H1 最像”,证伪会说“除了 H1 和勉强的 H4,其余在物理上根本不可能”。

3.4 算例 2:贝叶斯融合与奥卡姆惩罚(论文公式 3)

$$\log P(h | \Delta \mathbf{p}^{\text{obs}}) = \log P_0(h) + \log \mathcal{L}(h) - \frac{1}{2} k_h \log m - \log Z$$

三个部分(最后的 Z 是归一化常数,保证所有假设的概率加起来等于 1,见下文):

- 先验 $P_0(h)$ 。** 论文按家族分配基率:泄漏 0.50、需水 0.20、传感器 0.15、阀门 0.10、空假设 0.05,家族内平均分。玩具里 3 个泄漏假设各得 $0.50/3 = 0.1667$;3 个区的需水假设各 0.0667(表里只列了 A 区那个);4 个通道的传感器故障各 0.0375;阀门 0.10;空 0.05。
- 似然 $\log L$ 。** 上一步算好了。
- 奥卡姆惩罚 $\frac{1}{2} k \log m$ 。** k 是这个假设“调了几个旋钮”。泄漏假设调了两个(节点、流量),惩罚 $\frac{1}{2} \times 2 \times \ln 4 = \mathbf{1.386}$;需水假设调一个,惩罚 **0.693**;阀门和空假设不调,惩罚 0。

为什么一定要罚? 因为泄漏假设最“灵活”:它可以在几十个节点、六档流量里挑最像的,总能凑出个不错的拟合。不罚它,它就会冒充需水异常。论文的消融实验(论文数据,SI Table S4)证实了这一点:去掉惩罚,“需水异常被误判为泄漏”的次数从 1/100 涨到 9/100,涨了九倍。

得分 = $\ln$ 先验 + $\log L$ - 惩罚,再做归一化(把每个得分取指数、除以所有假设的指数之和,让各假设概率加起来等于 1;这一步机器学习里叫 softmax,公式里的 Z 就是那个和)。 结果(脚本算例 1):

假设	先验	log L	惩罚	后验概率
H1 A 区泄漏	0.1667	8.01	1.386	0.9837
H4 A 区需水异常	0.0667	4.13	0.693	0.0163
其余 5 个				≈ 0

从后验里读出监督者要看的三个量(SI 公式 S5):

- **泄漏存在概率 Π_{exist}** = 所有泄漏假设后验之和 = 0.9837
- **领先边际 Δ** = 第一名减第二名 = 0.9837 - 0.0163 = 0.9675
- 第二名是谁、它的概率多大:H4,0.0163

3.5 算例 3:目标合同,行不行动(论文公式 4)

监督者的合同是六条硬检查的“与”:

$$\text{ACT} \Leftrightarrow G1 \wedge G2 \wedge G3 \wedge G4 \wedge G6 \wedge G7$$

用论文 EXA7 基准的阈值预设(论文数据,Methods): $\tau_e = 0.5, \delta = 0.12, \alpha = 0.20, R_{\text{max}} = 60$ 个节点, $\rho_{\text{max}} = 3$ 。假设 H1 圈出的候选区域有 18 个节点。

检查	含义	本例取值	阈值	结果
G1 存在	第一名是泄漏,且 $\Pi_{\text{exist}} \geq \tau_e$	是泄漏;0.9837	≥ 0.5	通过
G2 区域	候选区域够小,开挖队搜得完	18 个节点	≤ 60	通过
G3 边际	第一名领先 任何家族 的第二名够多	0.9675	≥ 0.12	通过
G4 备选	最强的对手本身也不可信	0.0163	≤ 0.20	通过
G6 残差	第一名在物理上重现了观测	$\rho = 0.39$	≤ 3	通过
G7 安全	不含任何越界操作	无	空集	通过

(G5 是实现里预留给部署的一个字段(标定有效性),本研究中**不参与求值**,所以不出现在公式里;同样预留而未求值的还有一个人工复核标志。)

六条全过 → **ACT:批准对 A 区派单**。监督者同时签发一份证书,记录:决定、合同版本和阈值、每条检查的实测值和通过与否、被接受的假设和区域,以及一个 SHA-256 摘要把证书绑定到证据包上;事后任何人改一个数字,摘要就对不上。这就是“可问责”的物质基础:**不是系统说它有把握,而是每一条依据都留了案、都能复算。**

3.6 算例 4:模棱两可怎么办,索证与主动感知(SI 公式 S6)

换一天,观测变成:

$$\Delta p^{\text{obs}} = [-0.22, -0.20, -0.21, -0.19] \text{ m}$$

四个传感器都均匀地掉了 0.2 m 左右。李生说:A 区泄漏预测 [-0.24, -0.21, -0.18, -0.17],B 区泄漏预测 [-0.19, -0.20, -0.24, -0.21]。两者都能重现观测(ρ 分别 0.42 和 0.47),融合之后(脚本算例 2):

假设	ρ	后验
H1 A 区泄漏	0.42	0.4742
H2 B 区泄漏	0.47	0.4378
H6 阀门 V1	1.21	0.0880
其余		≈ 0

$\Pi_{\text{exist}} = 0.912$ (肯定漏了),但 $\Delta = 0.0365 < 0.12$ (G3 失败),第二名 $0.4378 > 0.20$ (G4 失败)。合同不批。

关键在于:监督者**不会**因此就随便挑一个。它返回一个结构化请求:“G3 未通过,请分离 A、B 两区”。执行者于是做**主动感知**:在还没装传感器的候选节点里,找一个让 A、B 两个假设的预测**差别最大**的节点去补测(SI 公式 S6,即“李生可区分性”准则):

候选隐藏节点	A 区泄漏预测	B 区泄漏预测	差别
x1	-0.55 m	-0.05 m	0.50 m
x2	-0.30 m	-0.28 m	0.02 m

选 x1(去 x2 测了也白测,两个假设在那里读数一样)。玩具里只补测一个点;论文的实现是每轮按同一准则揭示得分最高的 3 个隐藏节点。假设补测得到 $x1 = -0.52 \text{ m}$,把它并入观测(m 变成 5)重新拟合(脚本算例 2b):A 区泄漏 $\rho = 0.46$ 仍然完美,B 区泄漏 ρ 飙到 4.22 被证伪,后验 A 区 ≈ 1.000 , $\Delta \approx 1.000$,**六条全过,ACT**。

如果预算内的几轮补测仍分不开,系统就**弃权**:输出一份卷宗,里面是仍然存活的假设和每条检查失败的原因,交给人类判断。弃权是正式结局,**永远不会被偷偷换成一个“最可能”的猜测**。

论文数据提醒一句:在 EXA7 的头条泄漏集上主动感知没有平均收益(分区准确率前后都是 81.67%,逐 seed 在 -5.0 到 +3.3 个百分点之间波动),因为那里的基础定位已经不错;它的收益出现在含最弱泄漏的扩展集上(70.5% 到 74.5%);它是为“低覆盖、高噪声”场景准备的后手,论文没有夸大它。

3.7 算例 5:审计员怎么抓“造假”

审计员收到的只是证据包的数字摘要,大致长这样(字段见 SI S6):


```
top_hypothesis: {type: leak, partition: A, posterior: 0.93,
                  fit_residual_mahalanobis: 7.8, candidate_region_nodes: 18}
leak_existence_probability: 0.93
margin_over_next_best: 0.88
alternatives: [{type: demand, partition: A, posterior: 0.05,
                 residual_mahalanobis: 1.3, status: open}, ...]
```

一眼就该看出问题:后验 0.93 说“很有把握”,残差 $p = 7.8$ 却说“这个假设根本重现不了观测”。一个诚实的证据包里这两件事不可能同时成立。审计员输出严格 JSON: `{"reject": true, "reason": "high posterior with incompatible residual"}`。

论文用三类“腐败包”做压力测试(论文数据,Results 末节与 SI Table S9):

- **无据断言**:高概率配上物理不相容的残差(就是上面这个);
- **伪造排除**:把一个残差其实拟合得很好的备选标成“已证伪”;
- **证据注水**:存在概率很低、边际几乎为零,却被写成“决定性”。

结果:16 个腐败包 **16/16 全部抓住**,16 个正常包 **0/16 误报**,同一输入重复 8 次判决完全一致(同一次会话内、温度为零)。样本不大(精确 95% 置信区间分别是 79 到 100%、0 到 21%),论文也如实写了。

一句话:审计员抓的是**数字之间的自洽性**,不是“读起来像不像真的”。这正是为什么它只能看数字、不能看叙述。

那为什么非要用大模型,写五条规则不行吗? 这个问题论文正面回答了(SI Table S15)。审计员的提示词本身就列了五条规则,上面三类腐败包各触发一条,所以一段十行的代码同样能拿到 16/16。于是论文又构造了四类**不在任何规则里、但每个字段单看都合规、合起来却不可能**的腐败包:边际大于泄漏存在概率、某个备选的后验高于第一名、后验之和远超 1、候选区域为空。结果:用论文原来的提示词(结尾写着“否则接受”),大模型表现得就像一个规则执行器,64 个包只抓住 0 到 2 个;只加一句“任何其他内部不自洽也拒绝”、不列举任何新规则,论文的审计模型按明确判断抓住 49 个(三类算术违规 48/48 全中,理由写的是“后验之和不能超过 1”“存在概率 0.72 与第一名后验 1.0 不能同时成立”这类真推理;“空区域”只抓到 1 个),对 16 个正常包**判断误报为零**;另一家的模型抓住 22 个、零误报。所以诚实的结论是:大模型提供的是**规则清单给不了的、可泛化的自洽性检查**,但它不能替代硬检查(空区域这种“实用判断”它基本放过),这就是它在架构里“只能加否决、不能推翻”的原因。

顺带一个真实的故事。 这个实验的第一轮里,开放式审计员曾对 4 个“正常包”报警,理由是“边际与后验算不上”。核查后发现它是对的:主动感知一轮之后,代码只改写了边际字段,没有同步重新分配各假设的后验,证据包因此不自洽。作者修了这个 bug,把论文里所有仿真数字重新跑了一遍(EXA7 头条从 97.6% @ 37.5% 变为 96.1% @ 40.5%),修好后同一个审计员对同一批正常包不再有判断误报。这就是“每个数字都可被独立复算”这一原则的价值:审计员抓到的不是造假,是作者自己的错误。

第 4 章 读懂论文的真实结果

以下数字全部是论文数据,请对照论文 Table 1、Fig. 4、Fig. 5 与 SI。

4.1 EXA7 基准:三个台阶

EXA7 是 381 个节点、15 个分区、30 个传感器的仿真基准,噪声 $\sigma = 0.05$ m,测试集混合了泄漏、需水异常、传感器故障和阀门误态,5 个随机种子。

台阶	谁	指标	数值
1	检索式定位器(每次必答)	分区 top-1 准确率	$31.7 \pm 2.0\%$
2	执行者的孪生拟合(每次必答)	分区 top-1 准确率	$81.7 \pm 5.0\%$
3	监督者的合同(允许弃权)	行动事件上的决策精度	$96.1 \pm 3.3\%$,覆盖率 40.5%
3'	把残差闸门拧紧	决策精度 100% 时的覆盖率	$13 \pm 15\%$

怎么读“覆盖率 40.5%,精度 96.1%”:系统对 40.5% 的事件行动,其中 96.1% 是对的;剩下 59.5% 弃权。第 1 章的“100 次报警”就是这行数字。

噪声升高时它怎么坏(这一点很关键)。把噪声从 0.02 m 提到 0.05 m 再到 0.10 m,分区准确率从 94.3% 降到 81.7% 再降到 70.7%,但行动精度只从 98.1% 到 96.1% 到 91.3%;真正付出代价的是“100% 精度下的覆盖率”,从 29.3% 掉到 12.9% 再掉到 6.9%。换句话说,**噪声越大,系统越倾向于闭嘴,而不是乱挖。**这就是一个派单系统应有的失败方向。

风险-覆盖曲线怎么看(论文 Fig. 4a)。横轴是覆盖率(对多少比例的事件行动),纵轴是精度。把阈值从严到松扫一遍就画出一条曲线。论文的合同曲线整体压在“只看泄漏存在分数”的单指标曲线之上;在代表性种子上,合同曲线可以在 100% 精度下走到 39% 覆盖率,单指标曲线最严也要放进 45.5% 的事件、精度最高只有 96%。原因就是第 3 章的 G3、G4、G6:单一分数分不开的“领先者被对手紧咬”和“物理上重现不了”的事件,合同能一条条否掉。

4.2 鉴别诊断:干扰事件几乎不会被误挖

5 个种子合计 600 个泄漏、250 个干扰事件(SI Table S2):

- 需水异常 100 个,正确识别 99 个;
- **传感器故障从未被误判为泄漏**(原因见 3.3:两者活在不同的空间里);
- 250 个干扰事件里最终以“泄漏”为第一名的只有 10 个,合同又否掉了其中 9 个:
被当成泄漏派单的干扰事件是 1/250(0.4%);去掉鉴别诊断这一环,变成 50/250(20.0%)。

- 有 53 个真泄漏没被识别成泄漏,但其中 41 个被读成了分区级的需水异常(水力上最接近的解释),9 个被读成阀门误态,只有 3 个被读成“无异常”。它们的代价是覆盖率(不派单),不是错挖。

4.3 与训练出来的模型比

论文在场景库上训练了四个真正的定位器,并在与执行者相同的一批测试泄漏上评估(SI Table S3):最强的是余弦 k 近邻,72.0 ± 3.0%;图卷积网络只有 10.0 ± 1.2%,几乎就是 6.7% 的随机水平(这是给“数据饥渴型”方法的一个提醒:水司拿不出成千上万条带标签的真实泄漏)。执行者的孪生拟合是 81.7%,领先最强训练模型近十个百分点;这十个点来自“每个候选都必须在孪生里重现观测”,而不是来自见过更多样本。

同时论文也诚实地写了:在有正确标签可以标定阈值的 EXA7 上,合同 97.9% 对逻辑回归标定阈值 99.4%,比标定阈值低约 1.5 个百分点,并不“更好”。合同的优势在于**不需要标签**、每次拒绝都能说出是哪条检查没过,而不是分数更高。

4.4 L-Town:第三方生成的公开基准

先澄清一点: L-Town 不是实测数据。它是 BattLeDIM 2020 竞赛的官方基准,组织方用一份**被故意扰动过**的管网模型副本(改了管道粗糙度和管径来模拟“模型和现实对不上”,再加白噪声模拟测量噪声)生成了两年的 SCADA 序列,并注入了 33 处已知泄漏。论文用**未扰动的名义模型**去诊断这些数据,所以这是一次货真价实的“生成器和诊断模型不一致”的检验,只是不是“真实遥测”。论文各处的措辞都按此写。

结果:强制定位只有 15%(33 处对 5 处),系统对其中 4 处行动,**4/4 全对**(精确 95% 置信区间 40 到 100%),其余 88% 弃权。行动的 4 处都是突发大泄漏(起始压降 0.40 到 1.15 m)。

一个真实的合同算例(SI Table S6、S7)。把“只看泄漏存在分数”的规则和合同放在同样只准行动 4 次的条件下比:

- 事件 p523:存在概率 **0.98**(单指标规则第四名,会派单),但边际只有 **0.02**,合同用 G3 否决。事后看,单指标规则把它派到了**错误分区**。
- 事件 p866:存在概率只有 **0.52**,单指标规则看不上它,但边际 **0.15**(L-Town 用的是放宽后的“迁移预设”, $\delta = 0.10$;各预设见第 6 章速查表),合同接受,**正确**。
- 结果:合同 4/4 = 100%,单指标 3/4 = 75%。代价也如实报告:有一处定位正确的事件因边际 0.04 低于下限被弃权了。

这个例子最能说明第 3 章那套检查为什么不是摆设:**“有多大把握”和“有没有对手紧咬”是两件事。**

4.5 City D:194 单真实维修工单,以及一堵天花板

City D 是一家水司的真实区域管网(541 节点、79 个节流控制阀),水司提供了自己的 EPANET 模型和 2025 年 256 张漏损维修工单,经过地址地理编码、三套坐标系交叉核对和严格入选过滤,留下 194 单、落在 46 个模型节点上。**节点位置是真实且经过审计的;但这些事件没有 SCADA,压力和流量观测是在孪生里仿真的**($\sigma = 0.15 \text{ m}$),论文对此处处标明。

算例 6:压力信息天花板。 194 单的中位漏损只有 0.106 L/s ,在这个刚性、高压的管网上,中位事件在 23 个传感器处产生的干净信号只有 0.002 m ,噪声是 0.15 m ,差了约 75 倍;哪怕取全部 541 个节点上的最佳信号(中位 0.0023 m ,SI Table S13,脚本算例 6 用的就是这个数),也差 **65 倍**,信号只有一个 σ 的 1.5%。更狠的是:哪怕在**全部 541 个节点上都装传感器**,194 单里也只有 5 单的最佳信号能超过 1σ 、只有 1 单能超过 0.45 m 的可行动门槛。这不是算法问题,是物理问题:**这批真实泄漏用压力根本看不见**。把需水量整体上下调 20 到 30% 重跑,结论纹丝不动(SI Table S14)。

在这个前提下,系统的表现是:强制定位 12%(23/194);合同只对 5 单派开挖,**3 单正确**(60%,但 5 个样本的精确 95% 置信区间是 15 到 95%,论文没有把它当成一个可靠的百分比);更严的“审计预设”(存在概率门槛提到 0.7、边际门槛提到 0.15、备选后验上限收到 0.20,见第 6 章速查表)下 **0 单派挖**;50 个无泄漏对照只误报 1 次(2%),审计预设下 0 次。论文的原话是:**当证据撑不起一次开挖,合同就拒绝一次开挖。**

于是加第二层:流量平衡巡查(脚本算例 4)。 泄漏有一个逃不掉的物理恒等式:它所在分区的净流入量会增加,增量恰好等于漏损流量(孪生在 194 单上逐一验证,中位比值 1.000)。假设每个分区进口装了流量计,夜间读数噪声 $\sigma_f = 0.10 \text{ L/s}$,在工单窗口内平均 W 个夜晚(上限 14),对 15 个分区做多重比较修正后门槛是 $u \cdot \sigma_f / \sqrt{W}$, $u = 3.4$:

平均夜数 W	门槛 $3.4 \times 0.10 / \sqrt{W}$	中位漏损 0.106 L/s 能否过线
1	0.340 L/s	不能
5(工单窗口中位数)	0.152 L/s	不能
14	0.091 L/s	能

所以大一点的泄漏、长一点的窗口过得去,小的过不去。全部算下来:**85/194(44%)被派往正确分区做声学巡查,分区精度 100%,50 次无泄漏对照 0 误报**;换成别的流量计假设,覆盖率在 29 到 56% 之间、精度 98 到 100%。这一层派的是“去哪个区细查”,不是“挖哪个点”,正好匹配这批小泄漏该用的手段。

4.6 鲁棒性与其他管网

- 28 组逐一改动的阈值下,合并精度始终在 89.9 到 99.1% 之间;最低那个来自把区域上限拧到 25 个节点,它把覆盖率掐到 8%,**即便阈值设错,也是朝“少行动”的方向错。**

- 同一套流程不改参数搬到 KY4(公开基准,959 节点)、City H(920 节点市政模型)和 City D 的仿真协议上:精度分别 96.3%、91.5%、81.8%,覆盖率随各网的信息量收缩,但每个网上都远高于各自的强制基线。

第 5 章 常见误解与诚实的边界

读完上面,几个容易想歪的地方:

1. **“Verifiable(可核验)” 不是统计保证。** 合同是一组确定性谓词,对每一个事件强制执行;它保证的是“系统只在六条检查全过时才行动、否则一定弃权、每条检查都留痕可复算”,**不保证**行动精度是某个数。论文 Methods 里明确写了这一句。事实上 City D 开挖层的 60%(3/5)就说明,谓词全过并不等于开挖一定正确:当信号被噪声淹没时,合同只能拒绝大多数,不能保证被接受的那几次全对。
2. **本研究没有任何一环使用实测的管网遥测。** L-Town 是组织方生成的;City D 的压力和流量是孪生仿真的;真实的是管网模型本身和经审计的泄漏位置。论文 Discussion 里明说了,下一步决定性的工作是接上真实 SCADA 的部署。
3. **样本很小的地方,不要读百分比,读分子分母。** L-Town 4/4,City D 3/5,审计 16/16 与 0/16。论文全部附了精确置信区间。
4. **仿真基准里“生成器”和“孪生”是同一个水力求解器**(只差噪声),这叫逆罪(inverse crime),会让仿真结果偏乐观;L-Town 之所以重要,就是因为它打破了这一点。
5. **语言模型不是精度的来源。** 双语言模型配置(gpt-oss-120b 规划、deepseek-v4-pro 审计)复现确定性流水线的行动/弃权决定 100% 一致,贡献的是可解释性;审计员对未列举的不自治只在被明确要求时才部分泛化(3.7 节末尾);所用模型通过 ollama 的云端托管端点调用,论文如实注明;研究期间曾有一个审计模型标签被服务方下线,所以复现依赖的是已提交的对话记录而不是端点。
6. **主动感知收益小、合同与标定阈值“相当”、开挖层 60% 的置信区间宽**,这些不利结论论文都没有删,评审时请留意它们确实在。

第 6 章 一页速查

符号

符号	含义
Δp^{obs}	传感器观测到的压力变化向量(m)
μ_h	假设 h 在数字孪生中预测的传感器变化
r_h, ρ_h	残差;每自由度马氏距离, $\rho \approx 1$ 合理, $\rho \gg 3$ 证伪
$P_0(h), k_h$	家族先验;假设的自由参数个数(泄漏 2、需水 1、传感器 = 通道数、阀门/空 0)
Π_{exist}	泄漏存在概率 = 所有泄漏假设后验之和
Δ	领先边际 = 第一名减(任何家族的)第二名
R, ρ_{max}	候选区域(节点数);残差上限 3

合同 ACT $\Leftrightarrow G1 \wedge G2 \wedge G3 \wedge G4 \wedge G6 \wedge G7$

检查	条件	EXA7 预设(也用于 KY4、City H、City D 的标准仿真协议)	迁移预设(L-Town、City D 工单)	审计预设
G1 存在	第一名是泄漏且 $\Pi_{exist} \geq \tau_e$	0.5	0.5	0.7
G2 区域	候选区域 $\leq R_{max}$	60	80	论文未单列
G3 边际	$\Delta \geq \delta$	0.12	0.10	0.15
G4 备选	第二名后验 $\leq \alpha$	0.20	0.30	0.20
G6 残差	$\rho(\text{第一名}) \leq 3$	3	3	3
G7 安全	无越界操作			

三种结局

结局	触发	产物
批准派单	六条全过(审计员也未加否决)	带 SHA-256 摘要的证书:决定、阈值、每条检查的实测值
索要证据	某条检查失败但可解决(典型:G3/G4 分区分不开)	指名失败的检查;主动感知补测最能区分的节点后重跑
弃权	轮次用完仍过不了	卷宗:存活假设 + 每条检查失败原因,交人复核

论文关键数字(EXA7 / L-Town / City D)

31.7% $\rightarrow$ 81.7% $\rightarrow$ 96.1% @ 40.5% 覆盖;100% @ 13 $\pm$ 15%;干扰事件误挖 1/250;L-Town 4/4(15% 强制基线);City D 开挖 5 单 3 对、审计预设 0 单、巡查层 85/194 @ 100% 分区精度、对照 0/50。

动手复现

```
python docs/tutorial_examples.py      # 本教程全部玩具算例
python reproduce_all.py               # 论文全部物理与统计数字和图(EXA7、KY4、
L-Town 用公开输入即可)
python tests/integrity_lint.py         # 检查没有任何指标是硬编码的
```

本教程由论文作者团队整理。玩具算例仅为教学;凡与论文正文、SI 或
artifacts/*.json 不一致之处,以后者为准。